

EDA

Exploratory Data Analysis

Průzkumová analýza dat

K čemu to je

- Důležitý první krok k
 - Poznání dat
 - Pochopení
 - Najít chyby, neobvyklá data
- Pomůže vybrat správné metody zpracování/analýzy



Typy EDA

Jednorozměrná analýza

- Když máme jednu dimenzi
- Jedna proměnná
- Histogramy, boxploty
- Souhrnné statistiky

Dvořozměrná analýza

- Dvě proměnné
- Abychom našli vztah, závislosti, korelaci,...
- Bodové grafy, čárové grafy,...

Vícerozměrná analýza

- jak spolu proměnné interagují
- Grafy
- Analýza hlavních komponent (PCA)
- Prostorová analýza

Úkoly v EDA



Průzkum dat

- Popisné statistiky
 - Průměr, medián, modus, součty, počty,...
- Variabilita
 - Rozsah, rozptyl, standardní odchylka, IQR, koeficient variation
- Vyvážení dat, tvar rozdělení
 - Šikmost, kurtóza
- Další statistiky
 - Korelace, test normalizace,....
- Distribuce dat
 - Grafy, tabulky



Co dál???

Zadání cvičení

- Na moodlu je šablona Jupyter notebooku
- Pokud nemáte, integrujte data do DuckDB
- Proveďte EDA pro výsek datasetu/databáze
 - Pro každou relevantní tabulku
- Dle předchozích slidů
- Struktura EDA

